

Четвертое задание. Статистический анализ

Четвертое задание. Статистический анализ

Исходный файл: первое задание - данные 20260328_200415.csv

Объем выборки: 184 объявлений.

Кратко для заказчика

- Связь между ценой и типом кузова подтверждена; сила связи слабая.
- Различие цен черных и серых автомобилей не подтверждено; эффект малый.
- Различия цен по типу двигателя не подтверждены; размер эффекта малый.
- Связь цены и мощности подтверждена; она положительная и умеренная.

1. Хи-тест на наличие связи между ценой и типом кузова

Что проверяли

- Нулевая гипотеза H_0 : ценовая категория автомобиля не связана с типом кузова.
- Альтернативная гипотеза H_1 : между ценовой категорией и типом кузова есть связь.
- Для применения χ^2 цену разделили на три категории: низкая, средняя и высокая.

Статистический вывод

- $\chi^2(4) = 13.771$, $p = 0.0081$.
- V Крамера = 0.193, то есть связь слабая.
- Минимальная ожидаемая частота = 12.72; тест применим к этой таблице сопряженности.

Четвертое задание. Статистический анализ

- Значение p меньше 0.05, поэтому вероятность получить такое распределение случайно невелика.

Содержательный вывод

- На уровне значимости 0.05 цена и тип кузова связаны статистически значимо.
- Для заказчика это означает, что тип кузова можно использовать как дополнительный признак ценового сегмента, но не как самостоятельный и главный фактор.
- Сила связи слабая, поэтому на цену одновременно заметно влияют и другие характеристики: марка, возраст, мощность и пробег.
- Для группы 'Внедорожник 5 дв.' чаще всего встречается категория 'Высокая цена' (39.8%).
- Для группы 'Прочее' чаще всего встречается категория 'Низкая цена' (51.3%).
- Для группы 'Седан' чаще всего встречается категория 'Низкая цена' (42.3%).

2. t-тест для выборок цен автомобилей черного и серого цветов

Что проверяли

- Нулевая гипотеза H_0 : средняя цена черных и серых автомобилей одинакова.
- Альтернативная гипотеза H_1 : средние цены различаются.
- Использован Welch t-test, потому что размеры групп и разброс цен могут отличаться.

Статистический вывод

Четвертое задание. Статистический анализ

- Черные автомобили: $n = 52$, средняя цена = 4 150 517 руб., медиана = 1 800 000 руб.
- Серые автомобили: $n = 36$, средняя цена = 2 546 320 руб., медиана = 1 900 000 руб.
- $t = 1.304$, $df = 57.16$, $p = 0.1975$.
- Cohen's $d = 0.238$, то есть эффект малый.
- Разница средних составляет около 1 604 197 руб. (63.0% относительно средней цены серых автомобилей).
- Значение p больше 0.05, поэтому наблюдаемую разницу средних нельзя считать надежно подтвержденной.

Содержательный вывод

- На уровне значимости 0.05 статистически значимого различия между ценами черных и серых автомобилей не найдено.
- Для заказчика это означает, что цвет кузова не стоит использовать как самостоятельный фактор ценообразования.
- Эффект малый, поэтому даже разница в рублях может быть практически слабой.

3. ANOVA для цен автомобилей с разным типом двигателя

Что проверяли

- Нулевая гипотеза H_0 : средние цены автомобилей одинаковы для всех типов двигателя.

Четвертое задание. Статистический анализ

- Альтернативная гипотеза H_1 : хотя бы один тип двигателя отличается по средней цене.
- Использована Welch ANOVA, потому что группы неравны по численности и разбросу.

Статистический вывод

- Welch ANOVA: $F = 2.587$, $df = (3; 22.15)$, $p = 0.0786$.
- Eta squared = 0.023, то есть эффект малый.
- Разрыв между самой дорогой и самой дешевой по средней цене группой составляет около 3 236 172 руб.
- Значение p больше 0.05, поэтому различия средних по типам двигателя нельзя считать статистически подтвержденными.
- Сводка по группам:
 - бензин: $n = 143$, средняя цена = 2 777 751 руб., медиана = 1 550 000 руб.
 - гибрид: $n = 6$, средняя цена = 3 529 167 руб., медиана = 2 945 000 руб.
 - дизель: $n = 26$, средняя цена = 6 013 923 руб., медиана = 3 085 000 руб.
 - электро: $n = 9$, средняя цена = 5 051 217 руб., медиана = 5 600 000 руб.

Содержательный вывод

- На уровне значимости 0.05 статистически значимых различий средних цен между типами двигателя не обнаружено.
- Самая высокая средняя цена в этой выборке у группы 'дизель' (6 013 923 руб.), а самая низкая у группы 'бензин' (2 777 751 руб.).

Четвертое задание. Статистический анализ

- Для заказчика это означает, что в текущей выборке сам тип двигателя пока не дает надежного самостоятельного объяснения цены.

4. Корреляционный анализ для цены и мощности

Что проверяли

- Нулевая гипотеза H_0 : линейной связи между ценой и мощностью нет.
- Альтернативная гипотеза H_1 : линейная связь между ценой и мощностью есть.
- Использован коэффициент корреляции Пирсона.

Статистический вывод

- Pearson $r = 0.401$, $p = 0.000000$, $R^2 = 0.161$.
- Объем выборки для анализа: $n = 184$.
- Связь положительная и по силе умеренная.
- Значение p меньше 0.05 , поэтому линейная связь статистически подтверждается.

Содержательный вывод

- На уровне значимости 0.05 линейная связь между ценой и мощностью статистически значима.
- Для заказчика это самый сильный сигнал в текущем анализе: с ростом мощности автомобили в среднем становятся дороже; примерно 16.1% изменчивости цены линейно связано с мощностью.
- Это не причинно-следственный вывод: высокая цена может быть связана не только с мощностью, но и с брендом, возрастом, сегментом и комплектацией автомобиля.

Четвертое задание. Статистический анализ

Итог для заказчика

- Самый полезный признак для объяснения цены в этой выборке: мощность.
- Тип кузова можно использовать как вспомогательный фактор сегментации, но эффект у него слабее.
- Цвет кузова в текущем наборе данных не стоит использовать как самостоятельный критерий цены.
- По типу двигателя лучше делать осторожные выводы и по возможности расширить выборку, особенно по гибридам и электромобилям.